

# Laboratorio 4: Deep Learning

Allan Paniagua 18084  
Gabriel Garcia 21352

Agosto 2024

# Laboratorio 4: Deep Learning

Allan Paniagua 18084

Gabriel Garcia 21352

Agosto 2024

## 1 Introducción

Este informe presenta el análisis y los resultados obtenidos durante el Laboratorio 4 de Deep Learning, donde se entrenaron dos modelos de Redes Neuronales Convolucionales (CNN) y un modelo K-Nearest Neighbors (K-NN) para la clasificación de imágenes en el dataset PolyMNIST.

## 2 Metodología

Se entrenaron dos modelos CNN con diferentes arquitecturas y un modelo K-NN. Se utilizaron técnicas de aumento de datos para mejorar la generalización de los modelos CNN.

### 2.1 Modelos CNN

- **Modelo 1 (CNN):** Arquitectura básica con una capa de convolución.
- **Modelo 2 (CNN):** Arquitectura más compleja con dos capas de convolución.

### 2.2 Modelo K-NN

Se utilizó un modelo K-NN con métrica Euclidiana y 3 vecinos para evaluar su rendimiento en la clasificación de imágenes.


## 3 Resultados

### 3.1 Modelos CNN

- **Modelo 1 (CNN):** Mejor precisión en validación: 99.16%.
- **Modelo 2 (CNN):** Mejor precisión en validación: 99.70%.

### 3.2 Modelo K-NN

- **Precisión en prueba:** 66.82%.
- **Informe de Clasificación y Matriz de Confusión:**



## 4 Discusión

Durante el entrenamiento de los modelos CNN, se observó que ambos modelos alcanzaron una alta precisión en los datos de validación. Sin embargo, hay indicios de que hubo un poco de sobre ajuste (overfitting), especialmente en el Modelo 1. Esto se puede deber a varias razones:

- El modelo puede haber sido demasiado complejo para la cantidad de datos disponibles, lo que resultó en un ajuste excesivo a los datos de entrenamiento.
- A pesar del uso de técnicas de aumento de datos, no se logró evitar completamente el sobreajuste, lo cual sugiere que podríamos necesitar más datos o regularización adicional.

También se notó que el modelo K-NN no tuvo un desempeño tan bueno como los modelos CNN. Esto puede ser porque el K-NN no maneja bien la

alta dimensionalidad y la variabilidad en los datos de imágenes. Este resultado era esperado, dado que las CNN están mejor adaptadas para la clasificación de imágenes.

## 5 Comparativa de Modelos

A continuación se presenta una gráfica comparativa de los resultados obtenidos para cada modelo:




Figure 1: Comparativa de precisión entre los modelos CNN y K-NN.

## 6 Conclusión

Los modelos CNN demostraron un rendimiento significativamente mejor en comparación con el modelo K-NN, con el Modelo 2 (CNN) logrando la mayor precisión en validación. El aumento de datos ayudó a mejorar la generalización de los modelos CNN, pero el sobre ajuste aún fue un desafío a considerar. Para futuros trabajos, se recomienda explorar más técnicas de regularización o aumentar el tamaño del conjunto de datos.